

腐蚀领域学术摘要文体特征与影响力关联分析

扩大化基线测试结果汇报

石洪旭

上海理工大学

2026 年 7 月 17 日

核心问题

学术摘要的文体特征是否与论文影响力（被引次数）存在关联？

- **研究对象：** 腐蚀科学领域英文论文摘要
- **基线阶段：** Corrosion Science 期刊 2023 年论文，共 377 篇
- **扩大阶段：** 6 本腐蚀期刊 2015–2026 年论文，共 5,821 篇
- **影响力指标：** 规范化引用计数 NCC（期刊×年份双维度归一化）

数据规模对比

	基线	扩大
样本量	377	5,821
期刊数	1	6
年份范围	2023	2015–2026
NCC 归一化	年份	期刊×年份

期刊	篇数
Materials and Corrosion	1,820
Corrosion	1,271
Anti-Corrosion Methods	895
Corrosion Engineering	873
Corrosion Science	690
Corrosion and Materials Degrad.	272
合计	5,821

当前特征体系（六项浅层文体特征）

缩写	特征	计算方式
ASL	平均句长	总词数 / 句号数
MWL	平均词长	去标点字符数 / 总词数
LD	词汇密度	(总词数 - 停用词) / 总词数
LC	词汇高级度(TTR)	不重复词类型数 / 总词令牌数
JD	术语密度	腐蚀术语命中数 / 总词数
HD	模糊语密度	模糊限制语命中数 / 总词数

已知问题


全部停留在词级和句级的简单计数，缺乏句法、篇章、语用维度。

测试一：Pearson 相关分析



特征	r	结论
MWL	+0.07	可忽略
LC	-0.03	可忽略
LD	-0.02	可忽略
ASL	+0.01	可忽略
JD	-0.01	可忽略
HD	+0.01	可忽略

结论

六项特征与 NCC 全部趋近于零。
5,821 条数据确认：线性关系不存在。



测试二：K-Means 聚类分析




结论

最优 $k = 2$ ，轮廓系数仅 0.18（远低于阈值 0.5）。六项特征无法划分有意义的风格群组。

测试三：决策树分类

决策树 (Max Depth = 3)



方法

NCC ≥ 1.0 为高影响力; max_depth = 3 分类树

	基线	扩大
首要特征	JD	LC
准确率	-	64%

结论

Accuracy $\approx$ 全猜低影响力。
LC 与 JD 均为弱信号 ($r = 0.31$)。

六项浅层文体特征对学术影响力 没有解释或预测能力

- 相关性分析：全部趋近于零
- 聚类分析：无法形成有意义的风格群组
- 决策树分类：准确率等于随机猜测

关键意义

不是“样本太小导致不显著”，而是“5,821 条数据上确实不成立”。三种方法互相印证，构成特征体系升级的实证基础。

恳请批评指正！